

Xcup 延迟优化同步单

第一层（纯逻辑，不动模型）修改已在 Android 端完成。本单按移植顺序列出每处改动的规则、位置与 iOS 落地要点，末尾附明确「保持不变」的部分与验证清单。

分支 `claude/xcup-video-latency-accuracy-iqu52w`

提交 `82d0e6b` → `a64ba2a`

2026-08-18

改动文件 **3**

适用：**离线模式**（VideoProcessActivity，含网页视频模式）+ **在线模式**（OnlineAnalysisActivity）

背景（供不了解本项目的人阅读）

Xcup 是智能飞机杯的配套 app。它一边分析视频画面（MobileNetV3Small + Temporal Average Pooling，三分类 `[normal_plot, oral, sex]`，输入 12 帧 × 160×160），一边分析音频（YAMNet + 微调分类器，三分类 `[sex, oral, noise]`，输入 2 秒 16 kHz），把两者融合成「转 / 不转」，再经蓝牙下发给设备；音频响度另外映射成 0-8 档强度。

三条流水线（本地视频 / 在线屏幕捕获 / 网页视频）分析逻辑一致，代码分布在 `VideoProcessActivity`（离线，兼网页模式）与 `OnlineAnalysisActivity`（在线）两个类里，**两处几乎是复制关系，改动必须成对进行**。

本轮要解决的问题是**动作识别延迟明显、转场处误判多**。诊断结论是延迟由六层串联叠加（模型窗口惯性、推理节拍、融合节拍、平滑窗口投票、蓝牙状态机、启动死区），其中「10 秒平滑窗口 + 蓝牙状态机」属于重复的防抖保护；误判的首要原因是阈值加在 `oral/sex` 合并之前。第一层只改逻辑与参数，不重训模型。

参数速查

除音频死区外，所有改动在两个 Activity 中完全一致；iOS 端对应的两条流水线同样都要改。

常量 / 参数	旧值	新值	说明
<code>MAIN_FUSION_INTERVAL</code>	1000 ms	500 ms	融合循环节拍

常量 / 参数	旧值	新值	说明
VIDEO_INFERENCE_INTERVAL	1000 ms	500 ms	视频推理步长（抽帧仍 250 ms）
SMOOTH_WINDOW_SIZE	10	6	6 条 × 500 ms ≈ 3 秒
SMOOTH_MIN_COUNT	字面量 3	常量 3	投票最少出现次数（新增常量，值不变）
VIDEO_THRESHOLD_NORMAL / _ACTION	0.5 / 0.75	删除	被分组阈值取代
VIDEO_D0_PROB_THRESHOLD	—	0.65	P(oral)+P(sex) 判「转」
VIDEO_PLOT_PROB_THRESHOLD	—	0.60	P(plot) 判「不转」
AUDIO_THRESHOLD_ACTION / _NOISE	0.5 / 0.6	删除	被分组阈值取代
AUDIO_D0_PROB_THRESHOLD	—	0.55	P(sex)+P(oral) 判「转」
AUDIO_NOISE_PROB_THRESHOLD	—	0.60	P(noise) 判「不转」
FUSION_FASTPATH_VIDEO_CONF / _AUDIO_CONF	—	0.70 / 0.70	一致性快通道门槛
VIDEO_PLOT_CONFLICT_CONF	—	0.80	构成「强冲突」所需的视频剧情置信度
FUSION_CONFLICT_MARGIN	—	0.15	视频需领先音频的置信度差
CONFLICT_MAX_HOLD_TICKS	—	4	冲突延迟上限，超过后强制放行
AUDIO_STRONG_START_CONF	—	0.75	强音频直通启动门槛
AUDIO_ONLY_START_TICKS	—	2	弱证据启动所需连续 tick 数

常量 / 参数	旧值	新值	说明
<code>audioOnlyDoStreak</code>	—	字段， 初值 0	弱证据 do 连续计数 (仅融合线程访问)
<code>conflictHoldTicks</code>	—	字段， 初值 0	强冲突连续计数（仅 融合线程访问）
音频死区（离线/网页）	4000 ms	2000 ms	硬编码在音频循环 内，在线模式无此项

逐项改动

按此顺序移植；1-2 是其余改动的前提。

01 分组概率决策（误判修复，最重要）

位置：`applyVideoResult()` 与音频循环的结果映射 —— 两个 Activity 各两处，共 4 处

旧 先 `argmax` 取单类，再用该单类概率过阈值，然后才把 `oral/sex` 归并为 `"do"`。
转场期 $P(\text{oral})=0.4$ 、 $P(\text{sex})=0.4$ 时「该转」总证据 0.8，却因单类 $0.4 < 0.75$ 被判成 `unclear`。

新 在归并后的分组概率上判定，判定顺序固定为「先 `do`、后 `Noise`、否则 `unclear`」，置信度取分组后的概率：

视频（类目顺序 `[plot, oral, sex]`）：

```
pDo = probs[1] + probs[2]; pPlot = probs[0]
pDo ≥ 0.65          → "do"      (confidence = pDo)
否则 pPlot ≥ 0.60 → "Noise" (confidence = pPlot)
否则                → ""        (confidence = 0, unclear)
```

音频（类目顺序 `[sex, oral, noise]`）：

```
pDo = probs[0] + probs[1]; pNoise = probs[2]
pDo ≥ 0.55          → "do"
否则 pNoise ≥ 0.60 → "Noise"
否则                → ""
```

iOS 要点：注意视频与音频的类目索引顺序不同（见上）。无效结果（`index < 0` 或概率数组长度 `< 3`）仍判 `unclear`。由于分析线程输出只剩 `"do" / "Noise" / ""`，融合循环里原来的 `oral → do` 归一化成了死代码，Android 端已删除，iOS 如有同样代码可一并删。

02 音频推理结果暴露完整概率

位置：`AudioInferenceHelper.AudioInferenceResult`

结果结构新增 `float[] probs` 字段（顺序 `[sex, oral, noise]`），`predict()` 返回分类器输出的拷贝；无效结果时为空数组。视频侧的 `Result.probs` 原本就有，无需改。

iOS 要点：给音频推理结果结构体加 `probs: [Float]`，改动 01 依赖它。

03 节拍加快：融合与视频推理 1000 → 500 ms

位置：MAIN_FUSION_INTERVAL、VIDEO_INFERENCE_INTERVAL

融合循环本身耗时约 40-60 ms，视频推理约 154 ms（含抽帧），2 Hz 完全可承受。抽帧节拍（250 ms）、音频推理节拍（1000 ms）、新鲜度过滤 MAX_AGE（2000 ms）都不变。

蓝牙不会因此过载：实际发送仍被状态机的 1600 ms 发送间隔与最短持续时间节流，只是决策采样更密。

iOS 要点：只改两个定时器的间隔常量；循环内「耗时补偿」逻辑
(nextDelay = max(0, interval - elapsed)) 保持原样。

04 平滑窗口收缩 10 → 6

位置：SMOOTH_WINDOW_SIZE；投票处字面量 3 改用 SMOOTH_MIN_COUNT

融合 tick 变为 500 ms 后，6 条记录约覆盖 3 秒（原来 10 条 × 1000 ms = 10 秒）。防抖职责统一收归蓝牙状态机，平滑窗口只压制单次抖动。加权评分公式、时间递增权重、模态权重（视频 0.8 / 在线 0.7，音频 1.2）、历史不足 3 条时的 selectBestAction 兜底逻辑全部不变。

iOS 要点：纯常量修改；如果 iOS 端窗口投票里也是硬编码的 3，顺手常量化。

05 一致性快通道

位置：`smoothedFusion()` 内部 —— 在「记录入窗 + 裁剪窗口」之后、投票之前

```
if videoAction 非空
  且 videoAction == audioAction
  且 videoConf ≥ 0.70 且 audioConf ≥ 0.70:
    return videoAction    // 绕过窗口投票
```

两个模态同 tick 高置信度一致时没有抖动嫌疑，不必攒票。对 "do" 与 "Noise" 都生效；停转方向的安全性仍由蓝牙状态机兜底（do→Noise 稳定 1000 ms + 最短持续 2000 ms）。

iOS 要点：本 tick 的记录必须先加入历史窗口再走快通道判断，否则窗口会漏账、影响后续投票与启动门控的证据检索。

06 启动仲裁：applyDoStartGate

位置：融合循环中，`smoothedFusion()` 之后、`updateBluetoothState()` 之前调用：

```
finalAction = applyDoStartGate(finalAction, videoAction, videoConf, audioAction, audioConf)。
```

新增方法 + 字段 `audioOnlyDoStreak`、`conflictHoldTicks`

设计前提（重要）：实测音频模型准确度高于视频模型。因此视频不对启动拥有否决权，只能在与音频强烈冲突时把启动短暂推迟，且推迟有硬上限。这与融合权重（音频 1.2 / 视频 0.8）的取向一致。

本项最初的版本让「视频高置信度剧情」直接否决启动，方向反了——较弱模态可以永久压制较强模态。下方是修正后的最终规则。

作用范围仅限「从非 do 状态启动 do」；已在 do 状态时（维持阶段）音频可单独维持，不受任何限制。

```

applyDoStartGate(finalAction, videoAction, videoConf, audioAction, audioConf)
    if finalAction != "do":                streak = 0; hold = 0; return finalAction
    if 当前蓝牙状态已是 do (维持阶段):    streak = 0; hold = 0; return finalAction

// — 以下为启动阶段 —
audioDoConf = (audioAction == "do") ? audioConf : 0

// 规则1 强冲突延迟 (有上限, 绝不永久阻塞)
strongConflict = videoAction == "Noise"
                且 videoConf ≥ 0.80
                且 (videoConf - audioDoConf) ≥ 0.15
if strongConflict:
    hold += 1
    if hold ≤ 4: return ""                // 本 tick 不启动
    // 超过上限 → 视频可能在系统性误判, 按“音频更可信”继续往下走
else:
    hold = 0

// 规则2 强音频直通
if audioDoConf ≥ 0.75: streak = 0; return finalAction

// 规则3 视频证据放行
if 平滑窗口内存在任一条 videoAction == "do":
    streak = 0; return finalAction

// 规则4 弱证据兜底
streak += 1
if streak ≥ 2: return finalAction
return ""

```

- 返回 "" 表示本 tick 不驱动蓝牙状态机（融合循环对空结果直接跳过发送），维持现状，不主动发 Noise。
- **最坏启动延迟有界**：4（冲突上限）+ 2（弱证据）= 6 tick ≈ 3 秒。任何情况下视频都无法永久阻塞音频。
- 两个计数器只在融合线程（主线程）读写，无需加锁；窗口证据检索需持有 historyLock。

- 重置点共 3 处（与清空动作历史同步）：离线 seek（`handleSeekComplete`）、网页模式 seek（`handleWebVideoSeekComplete`）、在线模式静音重置。两个计数器都要归零。

iOS 要点：这是唯一新增的方法级逻辑，两条流水线各复制一份（或抽公共函数）。「当前蓝牙状态已是 do」读的是状态机的 `currentBluetoothState`（已确认执行中的动作），不是融合输出。注意规则 1 命中上限后是继续往下执行规则 2-4，而不是直接放行。

调参提示：若实测仍嫌启动慢，优先把 `AUDIO_STRONG_START_CONF`（0.75）调低——它是最常命中的放行路径；若观察不到音频假启动，可把整个 `applyDoStartGate` 删掉，交由平滑窗口 + 蓝牙状态机兜底。

07 音频死区 4 s → 2 s（仅离线 / 网页模式）

位置：离线音频循环 `(currentMs - audioStartTime) ≥ 4000` → `≥ 2000`

模型窗口只需要 $[T-2s, T]$ 共 2 秒数据；解码器本身保持约 3 秒提前量；且

`readWindowRelaxed` 在有效样本不足 90% 时返回 null 自我保护，等满 2 秒即可开始尝试。起播与每次 seek 后的音频空窗因此缩短 2 秒。

在线模式没有这处改动：它用 `getLatestData()`，数据不足直接返回 null，自带门控。iOS 端只改离线 / 网页模式的等待常量。

明确保持不变

移植时不要顺手改这些 —— 防抖职责已统一收归蓝牙状态机，它的参数是刻意保留的。

- 蓝牙状态机全部参数：最短持续 2000 ms、发送间隔 1600 ms、do→Noise 需稳定 1000 ms、do/oral 确认 0 ms。
- 档位 / 节律链路：`computeFinalFreq`、方向性置信度门控 (0.10×3) 、档位迟滞 (± 1) 、`LEVEL_STABLE_MS = 0`、0-8 钳制。
- 模态权重：视频 0.8（在线模式 0.7）、音频 1.2；时间递增权重公式。
- 新鲜度过滤 `MAX_AGE = 2000 ms`；抽帧节拍 250 ms；12 帧滑窗；音频推理节拍 1000 ms。
- `selectBestAction`（历史不足时的兜底）与 seek 防抖、暂停 / 恢复、静音检测逻辑。

预期效果与验证清单

「剧情 → 动作」的启动延迟预计从约 5-8 秒降到约 2.5-4 秒；音视频一致高置信度时走快通道，延迟趋近「模型窗口惯性 + 0.5 s tick + 蓝牙门控」。停转方向仍偏保守，这是刻意的。四个分组阈值（0.65 / 0.60 / 0.55 / 0.60）与启动仲裁的五个参数都是初值，等第 0 层评测基准（逐秒标注的完整视频回放）建立后再校准。

- 转场片段：从剧情切入动作后设备起转时间明显缩短，转场期 `unclear` 输出显著减少。
- 音频先于画面判定动作（音频更准的典型场景）：起转不被视频拖住，日志应看到
[启动仲裁] 音频 `do` 置信度 ... 达直通门槛。
- 暗光 / 特写等视频易误判场景：不应出现「音频一直判 `do` 但设备始终不转」；最长延迟约 3 秒后必然放行。
- 剧情段带配乐 / 配音喘息：若确实出现假启动，检查是否为弱证据路径放行，据此调 `AUDIO_STRONG_START_CONF`。
- `seek`（离线与网页模式）：清空后恢复分析正常，音频空窗约 2 秒。
- 在线模式：静音暂停 → 恢复后两个计数器均从零开始，无残留状态。
- 蓝牙日志：发送频率没有因 500 ms 节拍上升（仍受 1600 ms 间隔约束）。

对应 Android 提交 82d0e6b（第一层改动）+ a64ba2a（启动仲裁修正），分支 `claude/xcup-video-latency-accuracy-iq52w`，仓库 `Tingfu-Zhou/xcup-android`· 涉及 `VideoProcessActivity.java` ·

`OnlineAnalysisActivity.java` · `AudioInferenceHelper.java`

后续计划：第 2 层 = 本地模式前瞻分析（分析 `currentMs` + 1500~2000ms 抵消模型窗口惯性）；第 3 层 = 难例挖掘重训、缩短模型输入窗口、流式视频模型。